


Le rôle de l'arbre de décision dans XGBoost

Note explicative — boosting de gradient appliqué à la prédiction de prix immobiliers

Dans XGBoost, un arbre de décision n'a pas le même rôle que dans un arbre de classification classique. Il ne renvoie pas une catégorie en sortie d'une feuille, mais un petit score numérique, une correction à ajouter à une estimation déjà existante. Le modèle final est simplement la somme de l'estimation de départ et de toutes les corrections apportées par chaque arbre, construits les uns après les autres. Le schéma ci-dessous illustre ce principe sur un exemple concret : estimer le prix d'une maison de qualité de construction élevée et de grande surface habitable, à partir du jeu de données utilisé pour le mémoire.



Lecture du schéma — gris : question posée par l'arbre sur une variable sarcelle : chemin suivi par notre exemple, avec la correction appliquée gris clair pointillé : branche non suivie dans cet exemple violet : étapes de la prédiction globale (départ et arrivée)

Comment lire ce schéma, étape par étape

1 Une estimation de départ très simple

Avant de regarder le moindre détail de la maison, le modèle part d'une valeur de base : le prix moyen observé sur l'ensemble des maisons du jeu de données, ici 180 000 \$. Ce n'est pas encore une prédiction utile, juste un point de départ commun à toutes les maisons.

2 Le premier arbre pose une question

Un arbre, dans ce contexte, n'est rien d'autre qu'une suite de questions simples du type « oui ou non » sur une caractéristique de la maison. La première question posée ici est : « la qualité de construction est-elle élevée, c'est-à-dire une note de 7 ou plus ? »

3 La réponse donne une petite correction

Pour notre maison de qualité élevée, la réponse est « non » au sens de la question posée dans le schéma (qualité inférieure à 7), donc on suit la branche de droite. Cette branche ne donne pas un prix, seulement un ajustement : + 15 000 \$. L'estimation passe alors de 180 000 \$ à 195 000 \$.

4 Un deuxième arbre, qui ne recommence pas de zéro

Le modèle construit un second arbre. Mais celui-ci ne regarde pas à nouveau le prix complet : il se concentre uniquement sur l'écart qu'il reste à corriger après le premier arbre. Sa question porte sur une autre caractéristique : « la surface habitable dépasse-t-elle 1500 pieds carrés ? »

5 Une deuxième correction s'ajoute

Notre maison ayant une grande surface, la réponse est « non » à la question posée (surface inférieure à 1500), et la branche suivie donne une correction de + 11 000 \$. Cette correction s'ajoute à l'estimation déjà corrigée par le premier arbre : $195\,000 \$ + 11\,000 \$ = 206\,000 \$$.

6 La prédiction finale est une somme

Dans un vrai modèle XGBoost, ce processus se répète des centaines de fois plutôt que deux. Chaque nouvel arbre, dont la contribution est volontairement réduite par un taux d'apprentissage, apporte une toute petite correction supplémentaire. La prédiction finale n'est rien d'autre que la somme de l'estimation de départ et de toutes ces petites corrections empilées.

Pourquoi un arbre plutôt qu'une régression linéaire ?

Une régression linéaire impose une forme à la relation entre les variables et le prix : elle suppose que chaque variable contribue de façon constante et additive, indépendamment des autres. Un arbre de décision, au contraire, découpe l'espace des variables en régions successives au moyen de seuils, ce qui lui permet de capturer des effets non linéaires et des interactions entre variables sans qu'on ait besoin de les spécifier à l'avance. Par exemple, l'effet de la surface habitable sur le prix peut être différent selon le niveau de qualité du bien, un arbre peut représenter cela naturellement, une régression linéaire simple ne le peut pas sans transformation manuelle des variables.

Qu'est-ce qui fait un « bon » arbre dans ce contexte ?

Contrairement à un arbre de décision classique, qu'on cherche souvent à rendre profond et précis, un arbre faible de boosting doit au contraire rester court : une profondeur de l'ordre de 3 à 8 niveaux est typique. Son rôle n'est pas d'apprendre toute la structure du problème à lui seul, mais de corriger un petit morceau d'erreur. Un arbre trop profond finirait par apprendre le bruit du résidu courant plutôt que le signal utile, c'est-à-dire par surapprendre. XGBoost limite ce risque par la régularisation, qui pénalise le nombre de feuilles et l'amplitude de leurs scores, et par le taux d'apprentissage, qui réduit la contribution de chaque arbre pour laisser de la place à ceux qui suivent. C'est la combinaison de nombreux arbres faibles et peu profonds, plutôt qu'un seul arbre fort, qui constitue la force du modèle.

À retenir : chaque arbre de XGBoost ne prédit pas le prix, il prédit une correction au résidu courant. Le modèle final additionne une estimation de départ et l'ensemble de ces corrections successives, chacune produite par un arbre court et régularisé.